

硬件安全题库 2 · 多模型评测报告

正确率与响应时间 —— 600 题库随机抽样 100 题 × 7 个模型 × 700 次请求

2026 年 9 月 27 日 · llmapi.isrc.ac.cn · temperature 0.1 · 逐条原始数据与脚本清单见附录 B

本次评测在《硬件安全题库 2》(600 题) 中**随机抽取 100 题**，对 7 个模型发起共 700 次答题请求（全部成功），测量正确率与响应时间。主要结论：

- **正确率 91.0%—93.0%**，模型间差距仅 2 个百分点，但整体比旧题库测评（96.0%—97.6%）**低 3—6 个百分点**：题库 2 明显更难。
- 差距几乎全部来自**多选题**（83.3%—87.5%，单选为 96.2%—98.1%）；“核心/扩展”难度标签反而未拉开差距（92.3% vs 88.5%—93.4%）。
- 分知识域看，**故障注入（70%—80%）与密码算法（78%—83%）**显著低于其余各域；处理器微架构、综合两域全员 100%。
- 87/100 题被 7 个模型全部答对；**6 题七个模型全部答错且作答完全一致**，另 1 题仅 1 个模型答对——强烈提示这 7 道题的参考答案存在争议，建议人工复核。
- 响应时间：**Claude-Sonnet-5 最快**（中位 2.4 s，P95 仅 5.1 s），Gemini-3.8-Flash 最慢（中位 8.0 s）；DeepSeek-V4.1-Flash 以中位 3.5 s 位居第二快，且**正确率并列第一**，综合表现最优。

测评配置	
题库	《硬件安全题库 2》共 600 题（单选 322 / 多选 278；核心 200 / 扩展 400；9 个知识域），选项数 4—7 个
抽样	随机抽取 100 题（随机种子 20260927，抽样结果固化于 sample_questions.json，可复现），构成见附录 A
模型	DeepSeek-V4.1-Flash、GLM-5.3、GLM-5.3-Flash、GPT-5.6-Sol、GPT-5.6-Terra、Claude-Sonnet-5、Gemini-3.8-Flash（与 2026-09-25 旧题库测评相同的 7 个模型，便于对比）
接口	llmapi.isrc.ac.cn（OpenAI 兼容 /v1/chat/completions），temperature = 0.1
提示与判分	系统提示要求只输出选项字母；答案提取优先识别加粗结论（如 **ABC** ），选项字母集合精确匹配判分；仅 1 条回复落入兜底解析
时延口径	单请求墙钟时间（客户端计时）；各模型并行推进，模型内部并发 4 线程，因此时延含服务端排队成分，尾部偏保守
规模	700 次请求，0 次最终失败（7 次瞬时错误经指数退避重试成功），总耗时 394 s

表 1：测评配置总览

全部逐题原始回复（含模型答案、判分、时延、token 数与回复原文）已保留于 bench2/results/〈模型〉.jsonl，明细汇总见 bench2/agg/results_all.csv（700 行），统计口径见 bench2/agg/stats.json。




图 1：七个模型总体正确率排名 (n = 100, 误差条为 95% Wilson 置信区间)

正确率高度收敛：DeepSeek-V4.1-Flash 与 GPT-5.6-Sol 以 93.0% 并列第一，Claude-Sonnet-5 以 91.0% 垫底，极差仅 2.0 个百分点。在 n = 100 下，单模型正确率的 95% 置信区间半宽约 ± 5 个百分点，各模型区间全部重叠——单次 100 题不足以在统计上区分这 7 个模型，名次差异应在抽样误差范围内理解。真正拉开差距的是下文的题型与知识域维度。

总体正确率一览（按正确率降序）								
排名	模型	答对	正确率	95% 置信区间	单选 (52)	多选 (48)	答错	错误构成 (单/多)
1	DeepSeek-V4.1-Flash	93	93.0%	[86.2%, 96.6%]	98.1%	87.5%	7	1 / 6
2	GPT-5.6-Sol	93	93.0%	[86.2%, 96.6%]	98.1%	87.5%	7	1 / 6
3	GLM-5.3	92	92.0%	[85.0%, 95.9%]	96.2%	87.5%	8	2 / 6
4	GLM-5.3-Flash	92	92.0%	[85.0%, 95.9%]	96.2%	87.5%	8	2 / 6
5	GPT-5.6-Terra	92	92.0%	[85.0%, 95.9%]	96.2%	87.5%	8	2 / 6
6	Gemini-3.8-Flash	92	92.0%	[85.0%, 95.9%]	98.1%	85.4%	8	1 / 7
7	Claude-Sonnet-5	91	91.0%	[83.8%, 95.2%]	98.1%	83.3%	9	1 / 8

表 2：总体正确率、分题型正确率与错误构成




图 2: 各模型时延的均值 / 中位数 / P95 对比




图 3: 各模型时延分布箱线图 (每模型 100 次请求)




图 4: 响应时间累计分布 (ECDF)，曲线越靠左代表整体越快

时延呈三个梯队：**Claude-Sonnet-5 一枝独秀**（中位 2.4 s，P95 仅 5.1 s，且箱体最紧，长尾风险最小）；DeepSeek-V4.1-Flash（中位 3.5 s）与 GPT-5.6-Terra（中位 3.9 s）构成第二梯队，其中 Terra 的 P95（11.2 s）是该梯队中最稳的；GLM 双子、GPT-5.6-Sol 与 Gemini-3.8-Flash 中位时延在 5.7–8.0 s 之间，P95 普遍超过 14 s。GLM-5.3 均值（10.9 s）明显高于中位数（5.7 s），说明其慢请求拖尾严重。

需要注意本口径为“并发 4 下的墙钟时间”，包含服务端排队：P95 与均值会因并发而膨胀，跨模型相对快慢仍有参考价值，但不宜当作单并发服务水平。

时延与输出统计（单位：秒；按中位数升序）								
模型	均值	中位	P90	P95	最快	最慢	中位输出 token	中位吞吐 (tok/s)
Claude-Sonnet-5	2.9	2.4	4.3	5.1	1.9	6.7	1	0.4
DeepSeek-V4.1-Flash	5.3	3.5	10.8	16.9	1.5	29.1	260	72.3
GPT-5.6-Terra	5.5	3.9	8.1	11.2	1.8	74.4	5	2.1
GLM-5.3	10.9	5.7	12.0	21.0	1.2	168.7	349	61.8
GPT-5.6-Sol	7.7	5.8	12.2	14.9	2.5	64.3	38	6.1
GLM-5.3-Flash	9.1	7.0	15.8	20.1	1.2	57.2	284	34.5
Gemini-3.8-Flash	10.6	8.0	13.4	17.4	4.6	88.0	265	31.7

表 3: 各模型时延明细与输出长度、生成吞吐




图 5：正确率与中位时延的权衡（气泡大小为中位输出 token 数，虚线为两维中位数分界）

以两维中位数为界分四象限：**DeepSeek-V4.1-Flash** 独处“快且准”的理想区；GPT-5.6-Sol 落在“准但偏慢”区；Claude-Sonnet-5 最快但正确率垫底，属于“快但略逊”；Gemini-3.8-Flash、GLM-5.3、GLM-5.3-Flash 落入“慢且无明显准确率优势”的不利区。气泡大小揭示另一层差异：Claude-Sonnet-5、GPT-5.6-Terra、GPT-5.6-Sol 输出近乎只有答案字母（中位 1/5/38 token），而 GLM、DeepSeek、Gemini 会附带简短解释（260–350 token）——后者的时延中有一部分是为更长输出付出的。




图 6：分题型正确率：单选（左）vs 多选（右）




图 7：分难度正确率：核心（39 题）vs 扩展（61 题）

题型是本次评测**最有区分度的维度**：单选正确率 96.2%—98.1%（各模型仅错 1—2 题），多选骤降至 83.3%—87.5%（错 6—8 题），落差达 9—13 个百分点。多选题要求完整命中最优字母集合，多答、漏答任何一项即判错，这对模型的边界把握能力要求显著更高。相比之下，“核心 / 扩展”标签几乎未拉开差距（92.3% vs 91.8%—93.4%），说明本库的难度信息更多由题型与知识域承载，而非难度标签。个别模型的偏科值得注意：Claude-Sonnet-5 核心题正确率全场最高（94.9%），扩展题却全场最低（88.5%）。



图 8：模型 × 知识域正确率热力图 (%)

知识域 × 模型 正确率（%，列按总体正确率排序）							
知识域	DS-V4.1	GPT-Sol	GLM-5.3	GLM-5.3F	GPT-Terra	Gem-3.8	Sonnet-5
TEE (n=13)	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	92.3%
供应链安全 (n=9)	88.9%	88.9%	88.9%	88.9%	88.9%	88.9%	88.9%
侧信道攻击 (n=13)	100.0%	100.0%	92.3%	92.3%	100.0%	100.0%	100.0%
处理器微架构 (n=9)	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%
密码算法 (n=18)	83.3%	83.3%	83.3%	83.3%	77.8%	83.3%	77.8%
故障注入 (n=10)	80.0%	80.0%	80.0%	80.0%	80.0%	80.0%	70.0%
硬件可信根 (n=18)	94.4%	94.4%	94.4%	94.4%	94.4%	94.4%	100.0%
综合 (n=2)	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%
调试接口安全 (n=8)	100.0%	100.0%	100.0%	100.0%	100.0%	87.5%	100.0%

表 4：知识域正确率明细（列标题缩写：GLM-5.3F = GLM-5.3-Flash，GPT-Sol = GPT-5.6-Sol，GPT-Terra = GPT-5.6-Terra，Sonnet-5 = Claude-Sonnet-5，Gem-3.8 = Gemini-3.8-Flash，DS-V4.1 = DeepSeek-V4.1-Flash；括号内 n 为该域题数）

知识域维度分化明显：**故障注入是全场最弱域**（各模型 70%—80%，共识错题 Y131、Z088 所在域），**密码算法次之**（78%—83%，六道全错题中三道在此）；供应链安全呈现罕见的完全一致（89% = 8/9，九个模型错同一道 Z186）。相反，处理器微架构与综合两域全员满分，硬件可信根、TEE、侧信道也都在 92% 以上。模型之间的知识域轮廓高度相似，未出现“某家独 strong 于某域”的互补格局。




图 9：题目共识分布：每道题被多少个模型答对




图 10：错误构成 (a) 与模型两两作答一致率 (b)

100 道题中 87 道被全员答对，错误高度集中：仅 13 道题出现错误，且多数题是“多家齐错”。六道题 (Y043、Y045、Y116、Y131、Z088、Z186) 被七个模型全部答错，且每道题七个模型给出的答案完全相同；Z115 仅 Claude-Sonnet-5 答对，其余六家同样给出一致答案。两两作答一致率高达 95%—100%。当互相独立的七个模型在同一道题上给出同一个“错”答案时，更可能的解释不是七家同时犯同一错误，而是参考答案本身值得商榷——这与旧题库测评中 Q087、Q094、Q123 的情形一脉相承，建议对下列题目逐题人工复核。

共识错题 (≤1 个模型答对，共 7 道)					
题号	知识域	题型	参考答案	七模型作答	题干摘句
Y043	密码算法	多选	ACE	ACF×7	某 CDN 服务商为全球数万台边缘节点上的海量域名提供 HTTPS 接入，架构组在设计证书撤销方案时给出...
Y045	密码算法	多选	BDE	CDE×7	某多租户 SaaS 平台规划密钥体系，评审中出现以下做法。其中符合分级与隔离设计原则的有？...
Y116	密码算法	多选	ABF	ABCF×7	某机构规划隐私计算平台，需要在不同场景中选择 MPC 多方安全计算、TEE、差分隐私 DP、联邦学习 F...
Y131	故障注入	多选	ACE	AEF×7	某研究者在细扫阶段同时随机改变注入位置与注入时机，得到一张故障率“云图”并准备直接据此确定攻击参数。对该...
Z088	故障注入	单选	B	A×7	技术研讨会上有人提问：为什么激光故障注入能实现单比特翻转或跳过单条指令，而 EMFI 通常只能造成较大范...
Z115	硬件可信根	多选	ACEF	ACE×6、ACEF×1	某 SoC 团队规划内置安全岛，评审时总结 Intel CSME、AMD PSP、Microsoft P...
Z186	供应链安全	多选	BDF	ADF×7	某检测算法在 Trust-Hub 全部基准电路上检出率达到 100%，团队据此宣传“该算法可应对真实供应...

表 5：共识错题清单：红色为参考答案，蓝色为各模型实际作答分布

除共识错题外，其余 6 道为个别模型的孤立失误 (Y066 双错、Y010/Y159/Y238/Y386/Y334 各 1—2 家漏选或多选)，多为多选题漏选一项的边缘失误，例如 Gemini-3.8-Flash 在 Y334 漏选 A、Claude-Sonnet-5 在 Y159 漏选 D。没有任何模型在单选题上出现“理解性连环错”，单选失分全部落在两道争议题 (Z088) 之外仅 Y066、Y010 两题。

非共识错题 (2-6 个模型答对)					
题号	知识域	题型	参考答案	答对	答错模型 → 其作答
Y010	密码算法	单选	C	6/7	GPT-Terra→A
Y066	侧信道攻击	单选	B	5/7	GLM-5.3→A, GLM-5.3F→A
Y159	故障注入	多选	ABD	6/7	Sonnet-5→BD
Y238	TEE	多选	ACE	6/7	Sonnet-5→CE
Y334	调试接口安全	多选	ABE	6/7	Gem-3.8→BE
Y386	密码算法	多选	ACE	6/7	Sonnet-5→AC

表 6：非共识错题清单




图 11：中位输出 token 数与中位生成吞吐

输出行为分成两派：GLM 双子、DeepSeek、Gemini 输出 260—350 token 的简短解析，生成吞吐以 DeepSeek-V4.1-Flash 最高 (72.3 tok/s)、GLM-5.3 次之 (61.8 tok/s)；Claude-Sonnet-5、GPT-5.6-Terra、GPT-5.6-Sol 严格遵守“只输出字母”的指令（中位 1—38 token）。对后者，“token/s”分母极小、数值不再代表生成速度（如 Terra 的 2.1 tok/s 实为几乎无输出），其时延主要消耗在排队与推理调度上。这一差异也提示：若下游应用需要带解析的回答，GLM / DeepSeek 系的输出格式更接近可用形态；若只要裸答案做自动判分，答案式输出更省时省 token。

新旧题库测评对比 (旧：2026-09-25, 126 题；新：本次, 随机 100 题)					
模型	旧正确率	新正确率	变化 (pt)	旧均延时 (s)	新中位延时 (s)
DeepSeek-V4.1-Flash	97.6%	93.0%	-4.6	3.0	3.5
GLM-5.3	96.8%	92.0%	-4.8	3.6	5.7
GLM-5.3-Flash	96.0%	92.0%	-4	4.1	7.0
GPT-5.6-Sol	97.6%	93.0%	-4.6	5.0	5.8
GPT-5.6-Terra	96.8%	92.0%	-4.8	9.0	3.9
Claude-Sonnet-5	96.0%	91.0%	-5	4.5	2.4
Gemini-3.8-Flash	96.8%	92.0%	-4.8	11.6	8.0

表 7：同一批模型在旧题库与题库 2 抽样上的表现对比

同一批模型全体从旧题库的 96.0%—97.6% 下降至 91.0%—93.0%，降幅 3.7—6.0 个百分点；其中 Claude-Sonnet-5 降幅最大（96.0%→91.0%），DeepSeek-V4.1-Flash 与 GPT-5.6-Sol 最抗跌（均 97.6%→93.0%）。原因不在模型退步，而在题库升级：题库 2 的多选占比更高（48% vs 35%）、多选答案普遍含 3—4 项、61% 为扩展题，且选项最多 7 个，整体对边界概念与多要点合并考查的要求更高。旧题库上“接近满分”的表面繁荣被题库 2 打破，模型间真实差距反而更清晰地显现在多选题与故障注入、密码算法两个知识域。

- **模型选型：**综合准确率与响应时间，DeepSeek-V4.1-Flash 为本次评测最优（正确率并列第一 93.0%，中位 3.5 s，生成吞吐 72 tok/s）；GPT-5.6-Sol 同为 93.0% 但时延约为前者 1.7 倍；对时延敏感的在线场景 Claude-Sonnet-5（中位 2.4 s、P95 5.1 s）值得以 2 个百分点正确率换取。
- **评测方法：**题库 2 有效拉开了模型差距（相对旧题库），但 7 模型在 100 题上的置信区间仍全部重叠；如需统计显著的名次，建议每模型 400 题以上或多次重复抽样。
- **题库修订：**建议人工复核 7 道共识错题（Y043、Y045、Y116、Y131、Z088、Z115、Z186）的参考答案；复核前可将这 7 题标记为“存疑”，避免污染后续评测。
- **判分口径：**当前多选“全对才得分”的口径对模型最严苛、区分度也最大；可补充 Jaccard 部分得分口径作为辅助维度。
- **后续工作：**单并发时延测量（剥离排队影响）、同一题多轮重复评测的稳定性（方差）分析、以及 3 模型投票集成在更大题量下的收益验证。

题库 2 全库与本次抽样构成对比			
维度	取值	全库 (600)	样本 (100)
题型	单选	322	52
题型	多选	278	48
难度	核心	200	39
难度	扩展	400	61
知识域	密码算法	111	18
知识域	硬件可信根	92	18
知识域	侧信道攻击	91	13
知识域	TEE	72	13
知识域	故障注入	72	10
知识域	处理器微架构	54	9
知识域	供应链安全	54	9
知识域	调试接口安全	46	8
知识域	综合	8	2

表 8：随机抽样（seed = 20260927）各维度构成与全库对比，比例基本一致

bench2/sample_questions.json	抽样的 100 道题全文（题干、7 个选项、答案、解析、考点），固定种子可复现
bench2/results/*.jsonl	原始数据 : 7 个模型逐题回复记录共 700 条（模型答案、判分、时延、token 数、回复原文截断 500 字）
bench2/agg/results_all.csv	700 行明细汇总表（UTF-8 BOM，可直接用 Excel 打开）
bench2/agg/stats.json	报告全部统计量的机器可读版本（本报告各表均由此生成）
bench2/charts/*.svg	本报告全部 11 幅图表的矢量原稿
bench2/bench2.py	评测脚本（随机抽样、并发请求、断点续跑、答案提取与判分）
bench2/report.py	聚合统计与图表生成脚本
bench2/run.log	评测运行日志（含重试记录）